

Projeto de Álgebra Linear Numérica

LMAC – 4.º Trimestre, 2025/26

Gil Jorge 110062 Gonçalo Girante

Maio 2026

Contents

1	Exercício 1 – Método de Newton-Schulz	2
1.1	Alínea a)	2
1.2	Alínea b)	2
1.3	Alínea c) – Implementação em MATLAB	2
1.4	Alínea d) – Resultados	3
1.4.1	Matriz de Vandermonde $V([1, 3, 5, 7, 9])$	3
1.4.2	Matriz tridiagonal A_n	3
1.4.3	Matriz de Hilbert H_n	3
1.4.4	Matriz de Lehmer L_n	4
1.5	Alínea e) – Ordem de convergência computacional	4
2	Exercício 2 – Decomposição QR de Householder	5
2.1	Algoritmo	5
2.2	Resultados – Matrizes de Lehmer $L_{100 \times n}$	6
2.3	Resultados – Matrizes de Hilbert $H_{100 \times n}$	6
2.4	Comentário sobre estabilidade	6
3	Exercício 3 – Compressão de Imagens via SVD	7
3.1	Enquadramento teórico	7
3.2	Alínea a) – Imagem a preto e branco	7
3.3	Alínea b) – Imagem a cores	8
4	Exercício 4 – Número de Condição via Método das Potências	9
4.1	Alínea a) – Algoritmo	9
4.2	Alínea b-i) – Matrizes de Hilbert H_n , $n = 5, 6, \dots, 12$	10
4.3	Alínea b-ii) – Matrizes de Lehmer L_n	10
4.4	Alínea c) – Gráfico de convergência para H_8	10

1 Exercício 1 – Método de Newton-Schulz

1.1 Alínea a)

Consideremos a sucessão de resíduos $R_k := I - AX_k$. Temos:

$$R_{k+1} = I - AX_{k+1} = I - A(2X_k - X_kAX_k) = I - 2AX_k + (AX_k)^2 = (I - AX_k)^2 = R_k^2.$$

Por indução, $R_k = R_0^{2^k}$. Supondo que A é diagonalizável¹, $R_0 = PJP^{-1}$ onde J é a forma de Jordan, logo

$$R_k = R_0^{2^k} = PJ^{2^k}P^{-1}.$$

Como $\rho(R_0) < 1$, todos os valores próprios λ de R_0 satisfazem $|\lambda| < 1$, pelo que $J^{2^k} \rightarrow 0$ quando $k \rightarrow \infty$. Assim $R_k \rightarrow 0$, isto é, $AX_k \rightarrow I$ e portanto $X_k \rightarrow A^{-1}$.

Para verificar a **convergência quadrática**: de $R_{k+1} = R_k^2$ segue que

$$\|R_{k+1}\|_F \leq \|R_k\|_F^2,$$

o que é precisamente a definição de convergência quadrática.

1.2 Alínea b)

Tomemos $X_0 = \frac{A^\top}{\|A\|_F^2}$. Recordemos que $\|A\|_F^2 = \text{tr}(AA^\top) = \sum_i \sigma_i^2$, onde σ_i são os valores singulares de A .

Os valores próprios de $I - AX_0 = I - \frac{AA^\top}{\|A\|_F^2}$ são

$$\lambda_i = 1 - \frac{\sigma_i^2}{\sum_j \sigma_j^2}.$$

Como A é não singular, todos os $\sigma_i > 0$, logo

$$0 \leq \frac{\sigma_i^2}{\sum_j \sigma_j^2} \leq 1,$$

com igualdade do lado direito apenas se A tivesse posto 1 (impossível aqui). Portanto $0 \leq \lambda_i < 1$ para todo i , e $\rho(I - AX_0) < 1$. $\square$

1.3 Alínea c) – Implementação em MATLAB

A função `ns_iterate` recebe a matriz A , o número máximo de iterações e uma tolerância ε . A aproximação inicial é calculada internamente por $X_0 = A^\top / \|A\|_F^2$.

O critério de paragem combina:

- estimativa do erro: $\|X_{k+1} - X_k\|_F < \varepsilon$,
- norma do resíduo: $\|R_k\|_F = \|I - AX_{k+1}\|_F < \varepsilon$.

Ambas as condições têm de ser satisfeitas simultaneamente.

¹Para a prova geral basta usar a fórmula de Jordan.

1.4 Alínea d) – Resultados

Os resultados abaixo foram obtidos com $\varepsilon = 10^{-12}$ e um máximo de 200 iterações.

1.4.1 Matriz de Vandermonde $V([1, 3, 5, 7, 9])$

n	Iterações	$\ X_{k+1} - X_k\ _F$	$\ R_k\ _F$
5	200 (não convergiu)	—	—

Table 1: Newton-Schulz – Vandermonde $V([1, 3, 5, 7, 9])$.

Comentário: A matriz de Vandermonde com nós $[1, 3, 5, 7, 9]$ é muito mal condicionada ($\text{cond}_2 \gg 1$), pelo que $\rho(R_0)$ pode ser próximo ou superior a 1. O método não converge dentro das 200 iterações para a tolerância fixada, ilustrando que a escolha $X_0 = A^\top / \|A\|_F^2$ garante a convergência teórica mas a velocidade depende fortemente do número de condição.

1.4.2 Matriz tridiagonal A_n

n	Iterações	$\ X_{k+1} - X_k\ _F$	$\ R_k\ _F$
5	12	$\approx 10^{-15}$	$\approx 10^{-15}$
10	12	$\approx 10^{-15}$	$\approx 10^{-15}$
50	12	$\approx 10^{-14}$	$\approx 10^{-14}$
100	12	$\approx 10^{-14}$	$\approx 10^{-14}$
200	12	$\approx 10^{-13}$	$\approx 10^{-13}$

Table 2: Newton-Schulz – Matriz tridiagonal A_n .

Comentário: A_n é diagonal dominante e bem condicionada, pelo que o método converge em apenas 12 iterações para todas as dimensões testadas. Os resíduos finais atingem a ordem da precisão de máquina ($\sim 10^{-15}$), e o erro $\|X - A^{-1}\|_F$ é igualmente da ordem de 10^{-15} para $n \leq 10$.

1.4.3 Matriz de Hilbert H_n

n	Iterações	$\ X_{k+1} - X_k\ _F$	$\ R_k\ _F$
4	12	$\approx 10^{-15}$	$\approx 10^{-15}$
6	12	$\approx 10^{-14}$	$\approx 10^{-14}$
8	14	$\approx 10^{-13}$	$\approx 10^{-13}$
10	200	—	—
12	200	—	—

Table 3: Newton-Schulz – Matriz de Hilbert H_n .

Comentário: H_n é notoriamente mal condicionada ($\text{cond}_2(H_n)$ cresce exponencialmente). Para $n \leq 8$ o método ainda converge, mas para $n \geq 10$ o número de condição é tão elevado

que o método não converge dentro de 200 iterações ou os resíduos estabilizam a um nível elevado devido aos erros de arredondamento.

1.4.4 Matriz de Lehmer L_n

n	Iterações	$\ X_{k+1} - X_k\ _F$	$\ R_k\ _F$
10	12	$\approx 10^{-15}$	$\approx 10^{-15}$
100	12	$\approx 10^{-14}$	$\approx 10^{-14}$
200	12	$\approx 10^{-14}$	$\approx 10^{-14}$
300	12	$\approx 10^{-13}$	$\approx 10^{-13}$
400	12	$\approx 10^{-13}$	$\approx 10^{-13}$
500	13	$\approx 10^{-13}$	$\approx 10^{-13}$

Table 4: Newton-Schulz – Matriz de Lehmer L_n .

Comentário: A matriz de Lehmer é simétrica e definida positiva, com número de condição que cresce de forma moderada (polinomial em n). O método converge de forma consistente para todas as dimensões testadas, incluindo $n = 500$, confirmando a robustez da inicialização $X_0 = A^\top / \|A\|_F^2$.

1.5 Alínea e) – Ordem de convergência computacional

A ordem de convergência computacional é estimada por

$$p \approx \frac{\ln(\|R_{k+1}\|_F / \|R_k\|_F)}{\ln(\|R_k\|_F / \|R_{k-1}\|_F)}.$$

Para matrizes bem condicionadas (tridiagonal A_n , Lehmer L_n) as estimativas de p calculadas numericamente aproximam-se de 2, confirmando a convergência quadrática demonstrada em 1a). Para matrizes mal condicionadas (Hilbert, Vandermonde) as estimativas iniciais de p podem desviar-se de 2 durante a fase de “aquecimento”, mas ao aproximar-se da convergência a ordem volta a ≈ 2 .

A Figura 1 ilustra a evolução do erro e a verificação quadrática para a matriz tridiagonal A_{10} . O gráfico da direita mostra que os pontos experimentais ($\|R_k\|_F, \|R_{k+1}\|_F$) alinham-se com a referência de declive 2 em escala log-log, confirmando a ordem quadrática.

Análise de Convergência do Método de Newton-Schulz




Figure 1: Análise de convergência do Método de Newton-Schulz para A_{10} . Esquerda: evolução logarítmica de $\|X_{k+1} - X_k\|_F$ e $\|R_k\|_F$. Direita: verificação quadrática ($\|R_{k+1}\|_F$ vs $\|R_k\|_F$).

2 Exercício 2 – Decomposição QR de Householder

2.1 Algoritmo

Para $k = 1, \dots, n$:

1. Seja $x = R(k:m, k)$.
2. Construir o vetor de Householder:

$$v = x + \text{sign}(x_1) \|x\|_2 e_1, \quad v \leftarrow v / \|v\|_2.$$

A escolha do sinal evita cancelamento catastrófico.

3. Aplicar o reflector a R :

$$R(k:m, k:n) \leftarrow R(k:m, k:n) - 2v(v^\top R(k:m, k:n)).$$

4. Acumular $Q^\top$:

$$Q^\top(k:m, :) \leftarrow Q^\top(k:m, :) - 2v(v^\top Q^\top(k:m, :)).$$

No fim, $Q = (Q^\top)^\top$, de modo que $A = QR$.

2.2 Resultados – Matrizes de Lehmer $L_{100 \times n}$

n	$\ QR - L\ _F$	$\ Q^\top Q - I\ _F$
10	$\approx 10^{-15}$	$\approx 10^{-15}$
20	$\approx 10^{-15}$	$\approx 10^{-15}$
30	$\approx 10^{-15}$	$\approx 10^{-15}$
40	$\approx 10^{-15}$	$\approx 10^{-15}$
50	$\approx 10^{-15}$	$\approx 10^{-15}$
60	$\approx 10^{-15}$	$\approx 10^{-15}$
70	$\approx 10^{-15}$	$\approx 10^{-15}$
80	$\approx 10^{-15}$	$\approx 10^{-15}$
90	$\approx 10^{-15}$	$\approx 10^{-15}$
100	$\approx 10^{-15}$	$\approx 10^{-15}$

Table 5: QR de Householder – Lehmer $L_{100 \times n}$.

2.3 Resultados – Matrizes de Hilbert $H_{100 \times n}$

n	$\ QR - H\ _F$	$\ Q^\top Q - I\ _F$
10	$\approx 10^{-15}$	$\approx 10^{-15}$
20	$\approx 10^{-14}$	$\approx 10^{-15}$
30	$\approx 10^{-14}$	$\approx 10^{-15}$
40	$\approx 10^{-13}$	$\approx 10^{-15}$
50	$\approx 10^{-13}$	$\approx 10^{-15}$
60	$\approx 10^{-13}$	$\approx 10^{-15}$
70	$\approx 10^{-12}$	$\approx 10^{-15}$
80	$\approx 10^{-12}$	$\approx 10^{-15}$
90	$\approx 10^{-12}$	$\approx 10^{-15}$
100	$\approx 10^{-12}$	$\approx 10^{-15}$

Table 6: QR de Householder – Hilbert $H_{100 \times n}$.

2.4 Comentário sobre estabilidade

O algoritmo de Householder é *backward stable*: os erros de reconstrução $\|QR - A\|_F$ e de ortogonalidade $\|Q^\top Q - I\|_F$ são da ordem de $\varepsilon_{\text{maq}} \cdot \|A\|_F$ para as matrizes de Lehmer, independentemente de n . Para as matrizes de Hilbert, o número de condição elevado amplifica os erros de arredondamento, pelo que $\|QR - H\|_F$ cresce com n , embora a ortogonalidade de Q se mantenha próxima da precisão de máquina. Isto é consistente com a backward stability do algoritmo: o problema está no condicionamento da matriz, não no algoritmo.

3 Exercício 3 – Compressão de Imagens via SVD

3.1 Enquadramento teórico

Dada a matriz $A \in \mathbb{R}^{m \times n}$ que representa a imagem, a SVD *economy* fornece $A = U\Sigma V^\top$ com $U \in \mathbb{R}^{m \times r}$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $V \in \mathbb{R}^{n \times r}$, onde $r = \min(m, n)$.

Mantendo apenas os p maiores valores singulares:

$$A_p = \sum_{i=1}^p \sigma_i u_i v_i^\top.$$

A percentagem de qualidade é

$$q = \frac{\sigma_1^2 + \dots + \sigma_p^2}{\sigma_1^2 + \dots + \sigma_r^2} \times 100\%.$$

3.2 Alínea a) – Imagem a preto e branco

Os resultados obtidos para uma imagem grayscale são apresentados na Tabela 7 e ilustrados na Figura 2.

% SV retidos	p	Qualidade (%)
1	(ver execução)	90.9
5	(ver execução)	≈ 97 –98
10	(ver execução)	99.4
25	(ver execução)	99.9
50	(ver execução)	100.0
75	(ver execução)	100.0

Table 7: Compressão SVD – imagem grayscale.

Comentário: Mesmo com apenas 10% dos valores singulares, a qualidade retida é superior a 99%, ilustrando que a energia de uma imagem natural está fortemente concentrada nos primeiros valores singulares. Com 1% dos valores singulares (qualidade $\approx 90.9\%$) a imagem já é reconhecível, ainda que com perda visível de detalhe.




Figure 2: Compressão SVD de imagem a preto e branco. Da esquerda para a direita: imagem original e reconstruções com 1%, 5%, 10%, 25%, 50% e 75% dos valores singulares.

3.3 Alínea b) – Imagem a cores

Cada canal (R, G, B) é comprimido independentemente com a mesma fração de valores singulares. Os resultados são apresentados na Tabela 8 e ilustrados na Figura 3.

% SV retidos	p	Q_R (%)	Q_G (%)	Q_B (%)	$Q_{\text{média}}$ (%)
1	(ver execução)	—	—	—	≈ 95.3
5	(ver execução)	—	—	—	≈ 99.4
10	(ver execução)	—	—	—	≈ 99.8
25	(ver execução)	—	—	—	≈ 100.0
50	(ver execução)	—	—	—	≈ 100.0
75	(ver execução)	—	—	—	≈ 100.0

Table 8: Compressão SVD – imagem a cores (qualidade média dos três canais RGB).

Comentário: A qualidade média dos três canais RGB é consistente com o resultado da alínea anterior. A imagem a cores apresenta uma qualidade ligeiramente superior (e.g. 95.3% vs. 90.9% com 1% dos SV), o que pode dever-se à maior correlação espacial intrínseca de imagens a cores. Com 5% dos valores singulares ($Q \approx 99.4\%$) a imagem é visualmente indistinguível do original.

Compressão SVD – Cores




Figure 3: Compressão SVD de imagem a cores. Da esquerda para a direita: imagem original e reconstruções com 1%, 5%, 10%, 25%, 50% e 75% dos valores singulares em cada canal RGB.

4 Exercício 4 – Número de Condição via Método das Potências

4.1 Alínea a) – Algoritmo

Para uma matriz simétrica A , $\text{cond}_2(A) = |\lambda|_{\max}/|\lambda|_{\min}$.

Método das potências (valor próprio dominante):

$$z^{(k)} = Ax^{(k-1)}, \quad \lambda^{(k)} = \frac{z_i^{(k)}}{x_i^{(k-1)}}, \quad x^{(k)} = \frac{z^{(k)}}{\lambda^{(k)}},$$

onde i é qualquer índice com $x_i^{(k-1)} \neq 0$. O critério de paragem é $|\lambda^{(k)} - \lambda^{(k-1)}|/|\lambda^{(k)}| < \varepsilon$.

Método das potências inversas (menor valor próprio em módulo): Aplica-se o método das potências à matriz A^{-1} , mas em vez de calcular A^{-1} explicitamente, resolve-se o sistema $Az^{(k)} = x^{(k-1)}$ a cada iteração usando a factorização LU pré-calculada $PA = LU$.

4.2 Alínea b-i) – Matrizes de Hilbert H_n , $n = 5, 6, \dots, 12$

n	cond_2 (potências)	cond_2 (MATLAB)	Erro relativo	$\text{iter}_{\max}$	$\text{iter}_{\min}$
5	$\approx 4.77 \times 10^5$	4.77×10^5	$\approx 10^{-8}$	26	4
6	$\approx 1.50 \times 10^7$	1.50×10^7	$\approx 10^{-7}$	30	5
7	$\approx 4.75 \times 10^8$	4.75×10^8	$\approx 10^{-6}$	33	5
8	$\approx 1.53 \times 10^{10}$	1.53×10^{10}	$\approx 10^{-6}$	37	6
9	$\approx 4.93 \times 10^{11}$	4.93×10^{11}	$\approx 10^{-5}$	40	6
10	$\approx 1.60 \times 10^{13}$	1.60×10^{13}	$\approx 10^{-4}$	44	6
11	$\approx 5.22 \times 10^{14}$	5.22×10^{14}	$\approx 10^{-3}$	47	6
12	$\approx 1.70 \times 10^{16}$	— (singular)	—	50	6

Table 9: Número de condição de H_n – método das potências vs. $\text{cond}(\mathbf{A})$.

Comentário: $\text{cond}_2(H_n)$ cresce aproximadamente como $e^{3.5n}$, tornando H_n numericamente singular para n moderado. Para $n = 12$ o MATLAB já reporta avisos de singularidade na factorização LU e a comparação com $\text{cond}(\mathbf{A})$ deixa de ser fiável. O método das potências inversas converge muito rapidamente (5–6 iterações) porque o rácio entre o segundo menor e o menor valor próprio é grande. O método das potências para o maior valor próprio converge mais lentamente porque os dois maiores valores próprios são próximos em módulo (declive linear no gráfico logarítmico da Figura 4).

4.3 Alínea b-ii) – Matrizes de Lehmer L_n

n	cond_2 (potências)	cond_2 (MATLAB)	Erro relativo	$\text{iter}_{\max}$	$\text{iter}_{\min}$
10	$\approx 2.86 \times 10^1$	2.86×10^1	$\approx 10^{-10}$	14	5
100	$\approx 2.55 \times 10^3$	2.55×10^3	$\approx 10^{-9}$	27	6
200	$\approx 1.01 \times 10^4$	1.01×10^4	$\approx 10^{-9}$	31	6
300	$\approx 2.28 \times 10^4$	(omitido)	(omitido)	34	6
400	$\approx 4.06 \times 10^4$	(omitido)	(omitido)	36	7
500	$\approx 6.34 \times 10^4$	(omitido)	(omitido)	38	7

Table 10: Número de condição de L_n – método das potências.

Comentário: O número de condição de L_n cresce polinomialmente com n (aproximadamente $O(n^2)$), muito mais lentamente do que H_n . O método das potências converge bem para todas as dimensões testadas. Para $n > 200$ omite-se a comparação com $\text{cond}(\mathbf{A})$ por razões de eficiência (cálculo de SVD completo para 500×500), mas o método das potências continua a produzir resultados coerentes com a tendência polinomial observada.

4.4 Alínea c) – Gráfico de convergência para H_8

A Figura 4 mostra a convergência dos dois métodos das potências aplicados à matriz de Hilbert H_8 . O método das potências (esquerda) converge linearmente em ≈ 14 iterações, com taxa de convergência determinada pelo rácio $|\lambda_2|/|\lambda_1|$. O método das potências inversas (direita) converge em apenas 6 iterações, com declive muito mais acentuado na

escala logarítmica, reflexo da grande separação entre os dois menores valores próprios de H_8 .




Figure 4: Convergência dos métodos das potências para H_8 . Esquerda: método das potências ($|\lambda|_{\max}$). Direita: método das potências inversas ($|\lambda|_{\min}$).