

# Projeto de Álgebra Linear Numérica

LMAC – 4.º Trimestre, 2025/26

Gil Jorge 110062    Gonalo Girante 110370

Maio 2026

## Contents

|          |                                                                           |          |
|----------|---------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Exercício 1 – Método de Newton-Schulz</b>                              | <b>2</b> |
| 1.1      | Alínea a) . . . . .                                                       | 2        |
| 1.2      | Alínea b) . . . . .                                                       | 2        |
| 1.3      | Alínea c) – Implementação em MATLAB . . . . .                             | 3        |
| 1.4      | Alínea d) – Resultados . . . . .                                          | 3        |
| 1.4.1    | Matriz de Vandermonde $V([1, 3, 5, 7, 9])$ . . . . .                      | 3        |
| 1.4.2    | Matriz tridiagonal $A_n$ . . . . .                                        | 3        |
| 1.4.3    | Matriz de Hilbert $H_n$ . . . . .                                         | 4        |
| 1.4.4    | Matriz de Lehmer $L_n$ . . . . .                                          | 4        |
| 1.5      | Alínea e) – Ordem de convergência computacional . . . . .                 | 4        |
| <b>2</b> | <b>Exercício 2 – Decomposição QR de Householder</b>                       | <b>6</b> |
| 2.1      | Algoritmo . . . . .                                                       | 6        |
| 2.2      | Resultados – Matrizes de Lehmer $L_{100 \times n}$ . . . . .              | 7        |
| 2.3      | Resultados – Matrizes de Hilbert $H_{100 \times n}$ . . . . .             | 7        |
| <b>3</b> | <b>Exercício 3 – Compressão de Imagens via SVD</b>                        | <b>7</b> |
| 3.1      | Enquadramento teórico . . . . .                                           | 7        |
| 3.2      | Alínea a) – Imagem a preto e branco . . . . .                             | 8        |
| 3.3      | Alínea b) – Imagem a cores . . . . .                                      | 8        |
| <b>4</b> | <b>Exercício 4 – Número de Condição via Método das Potências</b>          | <b>9</b> |
| 4.1      | Alínea a) – Algoritmo . . . . .                                           | 9        |
| 4.2      | Alínea b-i) – Matrizes de Hilbert $H_n$ , $n = 5, 6, \dots, 12$ . . . . . | 10       |
| 4.3      | Alínea b-ii) – Matrizes de Lehmer $L_n$ . . . . .                         | 10       |
| 4.4      | Alínea c) – Gráfico de convergência para $H_8$ . . . . .                  | 10       |

# 1 Exercício 1 – Método de Newton-Schulz

## 1.1 Alínea a)

Consideremos a sucessão de resíduos  $R_k := I - AX_k$ . Temos:

$$R_{k+1} = I - AX_{k+1} = I - A(2X_k - X_kAX_k) = I - 2AX_k + (AX_k)^2 = (I - AX_k)^2 = R_k^2.$$

Por indução,  $R_k = R_0^{2^k}$ . Supondo que  $A$  é diagonalizável<sup>1</sup>,  $R_0 = PJP^{-1}$  onde  $J$  é a forma de Jordan, logo

$$R_k = R_0^{2^k} = PJ^{2^k}P^{-1}.$$

Como  $\rho(R_0) < 1$ , todos os valores próprios  $\lambda$  de  $R_0$  satisfazem  $|\lambda| < 1$ , pelo que  $J^{2^k} \rightarrow 0$  quando  $k \rightarrow \infty$ . Assim  $R_k \rightarrow 0$ , isto é,  $AX_k \rightarrow I$  e portanto  $X_k \rightarrow A^{-1}$ .

Para verificar a convergência quadrática: de  $R_{k+1} = R_k^2$  segue que

$$\|R_{k+1}\|_F \leq \|R_k\|_F^2,$$

o que é precisamente a definição de convergência quadrática.

## 1.2 Alínea b)

Tomemos  $X_0 = \frac{A^\top}{\|A\|_F^2}$ . Recordemos que  $\|A\|_F^2 = \text{tr}(AA^\top) = \sum_i \sigma_i^2$ , onde  $\sigma_i$  são os valores singulares de  $A$ .

Os valores próprios de  $I - AX_0 = I - \frac{AA^\top}{\|A\|_F^2}$  são

$$\lambda_i = 1 - \frac{\sigma_i^2}{\sum_j \sigma_j^2}.$$

Para justificar que os valores próprios de  $R_0 = I - \frac{AA^\top}{\|A\|_F^2}$  são da forma  $1 - \frac{\sigma_i^2}{\|A\|_F^2}$ , notamos que  $AA^\top$  é simétrica semidefinida positiva, pois  $x^\top AA^\top x = \|A^\top x\|^2 \geq 0$  para todo  $x \in \mathbb{R}^n$ . Os valores próprios de  $AA^\top$  são os quadrados dos valores singulares de  $A$ , ou seja  $\lambda_i(AA^\top) = \sigma_i^2$ . Portanto, se  $v_i$  é o vector próprio de  $AA^\top$  associado a  $\sigma_i^2$ :

$$\left(I - \frac{AA^\top}{\|A\|_F^2}\right)v_i = v_i - \frac{\sigma_i^2}{\|A\|_F^2}v_i = \left(1 - \frac{\sigma_i^2}{\|A\|_F^2}\right)v_i,$$

logo  $\lambda_i(R_0) = 1 - \frac{\sigma_i^2}{\|A\|_F^2}$ . Como  $A$  é não singular, todos os  $\sigma_i > 0$ , logo

$$0 \leq \frac{\sigma_i^2}{\sum_j \sigma_j^2} \leq 1,$$

com igualdade do lado direito apenas se  $A$  tivesse apenas um valor singular não nulo (impossível aqui uma vez que a matriz é não singular). Portanto  $0 \leq \lambda_i < 1$  para todo  $i$ , e  $\rho(I - AX_0) < 1$ .  $\square$

---

<sup>1</sup>Para a prova geral basta usar a fórmula de Jordan.

### 1.3 Alínea c) – Implementação em MATLAB

A função `ns_iterate` recebe a matriz  $A$ , o número máximo de iterações e uma tolerância  $\varepsilon$ . A aproximação inicial é calculada internamente por  $X_0 = A^\top / \|A\|_F^2$ .

O critério de paragem combina:

- estimativa do erro:  $\|X_{k+1} - X_k\|_F < \varepsilon$ ,
- norma do resíduo:  $\|R_k\|_F = \|I - AX_{k+1}\|_F < \varepsilon$ .

Ambas as condições têm de ser satisfeitas simultaneamente.

### 1.4 Alínea d) – Resultados

Os resultados abaixo foram obtidos com  $\varepsilon = 10^{-12}$  e um máximo de 200 iterações.

#### 1.4.1 Matriz de Vandermonde $V([1, 3, 5, 7, 9])$

| $n$ | Iterações | $\ X_{k+1} - X_k\ _F$  | $\ R_k\ _F$            | $\ X - A^{-1}\ _F$     |
|-----|-----------|------------------------|------------------------|------------------------|
| 5   | 42        | $3.89 \times 10^{-14}$ | $5.50 \times 10^{-13}$ | $4.29 \times 10^{-14}$ |

Table 1: Newton-Schulz – Vandermonde  $V([1, 3, 5, 7, 9])$ .

Contrariamente ao esperado para uma matriz muito mal condicionada, o método convergiu em 42 iterações. O número de condição elevado de  $V([1, 3, 5, 7, 9])$  implica que  $\rho(R_0)$  é próximo de 1, o que explica a convergência lenta (42 iterações vs.  $\approx 12$  para matrizes bem condicionadas), mas ainda dentro do limite de 200 iterações. O resíduo final  $\|R_k\|_F \approx 5.50 \times 10^{-13}$  e  $\|X - A^{-1}\|_F \approx 4.29 \times 10^{-14}$  confirmam que a solução é precisa.

#### 1.4.2 Matriz tridiagonal $A_n$

| $n$ | Iterações | $\ X_{k+1} - X_k\ _F$  | $\ R_k\ _F$            | $\ X - A^{-1}\ _F$     |
|-----|-----------|------------------------|------------------------|------------------------|
| 5   | 11        | $7.57 \times 10^{-17}$ | $3.01 \times 10^{-16}$ | $5.80 \times 10^{-17}$ |
| 10  | 12        | $2.43 \times 10^{-15}$ | $5.37 \times 10^{-16}$ | $4.90 \times 10^{-17}$ |
| 50  | 15        | $1.54 \times 10^{-16}$ | $7.15 \times 10^{-16}$ | —                      |
| 100 | 16        | $1.95 \times 10^{-16}$ | $8.69 \times 10^{-16}$ | —                      |
| 200 | 17        | $1.44 \times 10^{-16}$ | $8.28 \times 10^{-16}$ | —                      |

Table 2: Newton-Schulz – Matriz tridiagonal  $A_n$ .

$A_n$  é diagonal dominante e bem condicionada, pelo que o método converge rapidamente para todas as dimensões testadas. Os resíduos finais atingem a ordem da precisão de máquina ( $\sim 10^{-16}$ – $10^{-15}$ ), e o erro  $\|X - A^{-1}\|_F$  é igualmente da ordem de  $10^{-17}$ – $10^{-15}$  para  $n \leq 10$ . Note-se que o número de iterações cresce ligeiramente com  $n$  (de 11 para 17), o que é consistente com um ligeiro aumento do número de condição.

### 1.4.3 Matriz de Hilbert $H_n$

| $n$ | Iterações  | $\ X_{k+1} - X_k\ _F$ | $\ R_k\ _F$            | $\ X - A^{-1}\ _F$    |
|-----|------------|-----------------------|------------------------|-----------------------|
| 4   | 200 (n.c.) | $1.31 \times 10^{-9}$ | $1.85 \times 10^{-10}$ | $1.07 \times 10^{-9}$ |
| 6   | 200 (n.c.) | $4.85 \times 10^{-4}$ | $7.66 \times 10^{-5}$  | $1.06 \times 10^{-4}$ |
| 8   | 200 (n.c.) | $2.05 \times 10^2$    | $3.11 \times 10^1$     | —                     |
| 10  | 200 (n.c.) | $2.37 \times 10^8$    | $4.00 \times 10^7$     | —                     |
| 12  | 200 (n.c.) | $2.20 \times 10^{14}$ | $3.79 \times 10^{12}$  | —                     |

Table 3: Newton-Schulz – Matriz de Hilbert  $H_n$ . “n.c.” = não convergiu.

$H_n$  é notoriamente mal condicionada ( $\text{cond}_2(H_n)$  cresce exponencialmente com  $n$ ). Para nenhum dos valores testados o método convergiu dentro das 200 iterações para a tolerância  $\varepsilon = 10^{-12}$ . Para  $n = 4$  e  $n = 6$  os resíduos são ainda relativamente pequenos, mas crescem dramaticamente com  $n$ : para  $n = 12$  os erros atingem  $\sim 10^{14}$ , indicando divergência. Isto ocorre porque  $\rho(R_0) \geq 1$  para estas matrizes, violando a condição de convergência.

### 1.4.4 Matriz de Lehmer $L_n$

| $n$ | Iterações  | $\ X_{k+1} - X_k\ _F$  | $\ R_k\ _F$            | $\ X - A^{-1}\ _F$     |
|-----|------------|------------------------|------------------------|------------------------|
| 10  | 19         | $5.45 \times 10^{-13}$ | $2.96 \times 10^{-14}$ | $2.45 \times 10^{-14}$ |
| 100 | 200 (n.c.) | $1.49 \times 10^{-11}$ | $8.13 \times 10^{-11}$ | —                      |
| 200 | 200 (n.c.) | $1.23 \times 10^{-10}$ | $6.03 \times 10^{-10}$ | —                      |
| 300 | 200 (n.c.) | $3.88 \times 10^{-10}$ | $3.16 \times 10^{-9}$  | —                      |
| 400 | 200 (n.c.) | $1.10 \times 10^{-9}$  | $1.06 \times 10^{-8}$  | —                      |
| 500 | 200 (n.c.) | $2.02 \times 10^{-9}$  | $2.08 \times 10^{-8}$  | —                      |

Table 4: Newton-Schulz – Matriz de Lehmer  $L_n$ . “n.c.” = não convergiu.

Para  $n = 10$  o método converge em 19 iterações com resíduos de ordem  $10^{-14}$ . Para  $n \geq 100$ , o método não converge dentro de 200 iterações, embora os resíduos permaneçam moderados (crescendo de  $\sim 10^{-11}$  para  $\sim 10^{-8}$  com  $n$ ). Isto contrasta com o comportamento esperado para uma matriz de condição moderada: o número de condição de  $L_n$  cresce como  $O(n^2)$ , e para  $n$  grande  $\rho(R_0)$  aproxima-se de 1, tornando a convergência muito lenta. Aumentando o número máximo de iterações ou a tolerância, o método convergeria também para  $n$  grande.

## 1.5 Alínea e) – Ordem de convergência computacional

A ordem de convergência computacional é estimada por

$$p \approx \frac{\ln(\|R_{k+1}\|_F / \|R_k\|_F)}{\ln(\|R_k\|_F / \|R_{k-1}\|_F)}.$$

A Tabela 5 resume as ordens médias calculadas para cada família de matrizes, considerando apenas as estimativas finitas. Para as matrizes que não convergem, as estimativas são instáveis e sem significado físico, pelo que se reportam apenas para completude.

| Família                          | $n$        | Média de $p$ | Mín.     | Máx.   |
|----------------------------------|------------|--------------|----------|--------|
| Vandermonde $V([1, 3, 5, 7, 9])$ | 5          | 1.38         | -0.80    | 2.81   |
| 5*Tridiagonal $A_n$              | 5          | 1.51         | 0.03     | 2.00   |
|                                  | 10         | 1.56         | 0.18     | 2.00   |
|                                  | 50         | 1.55         | 0.05     | 1.97   |
|                                  | 100        | 1.58         | 0.07     | 1.97   |
|                                  | 200        | 1.61         | 0.03     | 1.98   |
| 5*Hilbert $H_n$ (n.c.)           | 4          | -0.61        | -10.61   | 2.56   |
|                                  | 6          | -0.93        | -194.33  | 34.10  |
|                                  | 8          | -9.88        | -1881.37 | 20.55  |
|                                  | 10         | -1.64        | -339.59  | 15.86  |
|                                  | 12         | 0.83         | -14.81   | 95.07  |
| 6*Lehmer $L_n$                   | 10         | 1.46         | 0.04     | 2.00   |
|                                  | 100 (n.c.) | -0.75        | -140.66  | 30.26  |
|                                  | 200 (n.c.) | -0.52        | -111.44  | 131.35 |
|                                  | 300 (n.c.) | -0.16        | -49.74   | 27.89  |
|                                  | 400 (n.c.) | -0.01        | -74.09   | 122.38 |
|                                  | 500 (n.c.) | -1.67        | -357.76  | 64.39  |

Table 5: Ordens de convergência computacionais do método de Newton-Schulz. “n.c.” = não convergiu; estimativas instáveis para esses casos.

Para as matrizes **tridiagonais** e **Lehmer**  $L_{10}$ , as ordens médias situam-se entre 1.46 e 1.61, com máximos próximos de 2, confirmando a convergência quadrática prevista pela teoria. A média ser inferior a 2 deve-se à fase transitória inicial (primeiras iterações com ordem  $\approx 1.3$ – $1.7$ ) antes de atingir o regime quadrático. Para a **Vandermonde**, a convergência é igualmente quadrática nas iterações finais (30–40), mas a longa fase transitória baixa a média para 1.38. Para a **Hilbert** e **Lehmer**  $n \geq 100$ , as estimativas são completamente instáveis (valores negativos e muito grandes em módulo), reflexo da divergência do método nestes casos.

A Figura 1 ilustra a evolução do erro e a verificação quadrática para a matriz tridiagonal  $A_{10}$ . O gráfico da direita mostra que os pontos experimentais ( $\|R_k\|_F, \|R_{k+1}\|_F$ ) alinham-se com a referência de declive 2 em escala log-log, confirmando a ordem quadrática.

## Análise de Convergência do Método de Newton-Schulz




Figure 1: Análise de convergência do Método de Newton-Schulz para  $A_{10}$ . Esquerda: evolução logarítmica de  $\|X_{k+1} - X_k\|_F$  e  $\|R_k\|_F$ . Direita: verificação quadrática ( $\|R_{k+1}\|_F$  vs  $\|R_k\|_F$ ).

## 2 Exercício 2 – Decomposição QR de Householder

### 2.1 Algoritmo

Para  $k = 1, \dots, n$ :

1. Seja  $x = R(k:m, k)$ .
2. Construir o vetor de Householder:

$$v = x + \text{sign}(x_1) \|x\|_2 e_1, \quad v \leftarrow v / \|v\|_2.$$

A escolha do sinal evita possíveis cancelamentos para valores negativos.

3. Aplicar o reflector a  $R$ :

$$R(k:m, k:n) \leftarrow R(k:m, k:n) - 2v(v^\top R(k:m, k:n)).$$

4. Atualizar  $Q^\top$ :

$$Q^\top(k:m, :) \leftarrow Q^\top(k:m, :) - 2v(v^\top Q^\top(k:m, :)).$$

No fim,  $Q = (Q^\top)^\top$ , de modo que  $A = QR$ .

## 2.2 Resultados – Matrizes de Lehmer $L_{100 \times n}$

| $n$ | $\ QR - L\ _F$         | $\ Q^\top Q - I\ _F$   |
|-----|------------------------|------------------------|
| 10  | $3.19 \times 10^{-15}$ | $3.47 \times 10^{-15}$ |
| 20  | $5.79 \times 10^{-15}$ | $5.02 \times 10^{-15}$ |
| 30  | $8.66 \times 10^{-15}$ | $5.71 \times 10^{-15}$ |
| 40  | $1.13 \times 10^{-14}$ | $6.31 \times 10^{-15}$ |
| 50  | $1.43 \times 10^{-14}$ | $6.83 \times 10^{-15}$ |
| 60  | $1.70 \times 10^{-14}$ | $7.27 \times 10^{-15}$ |
| 70  | $1.99 \times 10^{-14}$ | $7.50 \times 10^{-15}$ |
| 80  | $2.26 \times 10^{-14}$ | $7.78 \times 10^{-15}$ |
| 90  | $2.50 \times 10^{-14}$ | $8.11 \times 10^{-15}$ |
| 100 | $2.70 \times 10^{-14}$ | $8.25 \times 10^{-15}$ |

Table 6: QR de Householder – Lehmer  $L_{100 \times n}$ .

## 2.3 Resultados – Matrizes de Hilbert $H_{100 \times n}$

| $n$ | $\ QR - H\ _F$         | $\ Q^\top Q - I\ _F$   |
|-----|------------------------|------------------------|
| 10  | $9.72 \times 10^{-16}$ | $3.71 \times 10^{-15}$ |
| 20  | $1.02 \times 10^{-15}$ | $5.40 \times 10^{-15}$ |
| 30  | $1.06 \times 10^{-15}$ | $5.96 \times 10^{-15}$ |
| 40  | $1.08 \times 10^{-15}$ | $6.59 \times 10^{-15}$ |
| 50  | $1.10 \times 10^{-15}$ | $7.06 \times 10^{-15}$ |
| 60  | $1.11 \times 10^{-15}$ | $7.38 \times 10^{-15}$ |
| 70  | $1.12 \times 10^{-15}$ | $7.65 \times 10^{-15}$ |
| 80  | $1.13 \times 10^{-15}$ | $8.04 \times 10^{-15}$ |
| 90  | $1.14 \times 10^{-15}$ | $8.22 \times 10^{-15}$ |
| 100 | $1.15 \times 10^{-15}$ | $8.35 \times 10^{-15}$ |

Table 7: QR de Householder – Hilbert  $H_{100 \times n}$ .

O algoritmo de Householder é *backward stable*: os erros de reconstrução  $\|QR - A\|_F$  e de ortogonalidade  $\|Q^\top Q - I\|_F$  são da ordem de  $\varepsilon_{\text{maq}} \cdot \|A\|_F$  para as matrizes de Lehmer, independentemente de  $n$ . Para as matrizes de Hilbert, o número de condição elevado amplifica os erros de arredondamento, pelo que  $\|QR - H\|_F$  cresce ligeiramente com  $n$  (de  $9.72 \times 10^{-16}$  para  $1.15 \times 10^{-15}$ ), embora a ortogonalidade de  $Q$  se mantenha próxima da precisão de máquina. Isto é consistente com a backward stability do algoritmo: é consequência do condicionamento da matriz, não do algoritmo.

## 3 Exercício 3 – Compressão de Imagens via SVD

### 3.1 Enquadramento teórico

Dada a matriz  $A \in \mathbb{R}^{m \times n}$  que representa a imagem, a decomposição SVD permite  $A = U\Sigma V^\top$  com  $U \in \mathbb{R}^{m \times r}$ ,  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ ,  $V \in \mathbb{R}^{n \times r}$ , onde  $r = \min(m, n)$ .

Mantendo apenas os  $p$  maiores valores singulares:

$$A_p = \sum_{i=1}^p \sigma_i u_i v_i^\top.$$

A percentagem de qualidade é

$$q = \frac{\sigma_1^2 + \dots + \sigma_p^2}{\sigma_1^2 + \dots + \sigma_r^2} \times 100\%.$$

### 3.2 Alínea a) – Imagem a preto e branco

Os resultados obtidos para uma imagem grayscale são ilustrados na Figura 2. Mesmo com apenas 10% dos valores singulares, a qualidade retida é superior a 99%, ilustrando que a energia de uma imagem natural está fortemente concentrada nos primeiros valores singulares. Com 1% dos valores singulares (qualidade  $\approx 90.9\%$ ) a imagem já é reconhecível, ainda que com perda visível de detalhe.




Figure 2: Compressão SVD de imagem a preto e branco. Da esquerda para a direita: imagem original e reconstruções com 1%, 5%, 10%, 25%, 50% e 75% dos valores singulares.

### 3.3 Alínea b) – Imagem a cores

Cada canal (R, G, B) é comprimido independentemente com a mesma fração de valores singulares. Os resultados são ilustrados na Figura 3. A qualidade média dos três canais RGB é consistente com o resultado da alínea anterior. A imagem a cores apresenta uma qualidade ligeiramente superior (e.g. 95.3% vs. 90.9% com 1% dos SV), o que pode dever-se à maior correlação espacial de imagens a cores. Com 5% dos valores singulares ( $Q \approx 99.4\%$ ) a imagem é visualmente indistinguível do original.

### Compressão SVD – Cores




Figure 3: Compressão SVD de imagem a cores. Da esquerda para a direita: imagem original e reconstruções com 1%, 5%, 10%, 25%, 50% e 75% dos valores singulares em cada canal RGB.

## 4 Exercício 4 – Número de Condição via Método das Potências

### 4.1 Alínea a) – Algoritmo

Para uma matriz simétrica  $A$ ,  $\text{cond}_2(A) = |\lambda|_{\max}/|\lambda|_{\min}$ .

Dando uso ao método das potências (valor próprio dominante):

$$z^{(k)} = Ax^{(k-1)}, \quad \lambda^{(k)} = \frac{z_i^{(k)}}{x_i^{(k-1)}}, \quad x^{(k)} = \frac{z^{(k)}}{\lambda^{(k)}},$$

onde  $i$  é qualquer índice com  $x_i^{(k-1)} \neq 0$ . O critério de paragem é  $|\lambda^{(k)} - \lambda^{(k-1)}|/|\lambda^{(k)}| < \varepsilon$ .

Usando agora o método das potências inversas (menor valor próprio em módulo): aplica-se o método das potências à matriz  $A^{-1}$ , mas em vez de calcular  $A^{-1}$  explicitamente, resolve-se o sistema  $Az^{(k)} = x^{(k-1)}$  a cada iteração usando a factorização LU pré-calculada  $PA = LU$ .

## 4.2 Alínea b-i) – Matrizes de Hilbert $H_n$ , $n = 5, 6, \dots, 12$

| $n$ | cond <sub>2</sub> (potências) | cond <sub>2</sub> (MATLAB) | Erro rel.              | iter <sub>max</sub> | iter <sub>min</sub> | taxa $ \lambda_2/\lambda_1 $ |
|-----|-------------------------------|----------------------------|------------------------|---------------------|---------------------|------------------------------|
| 5   | $4.766 \times 10^5$           | $4.766 \times 10^5$        | $1.14 \times 10^{-11}$ | 13                  | 8                   | $1.331 \times 10^{-1}$       |
| 6   | $1.495 \times 10^7$           | $1.495 \times 10^7$        | $9.11 \times 10^{-12}$ | 14                  | 8                   | $1.497 \times 10^{-1}$       |
| 7   | $4.754 \times 10^8$           | $4.754 \times 10^8$        | $5.76 \times 10^{-10}$ | 15                  | 7                   | $1.637 \times 10^{-1}$       |
| 8   | $1.526 \times 10^{10}$        | $1.526 \times 10^{10}$     | $3.19 \times 10^{-10}$ | 15                  | 7                   | $1.758 \times 10^{-1}$       |
| 9   | $4.932 \times 10^{11}$        | $4.932 \times 10^{11}$     | $2.87 \times 10^{-7}$  | 16                  | 7                   | $1.864 \times 10^{-1}$       |
| 10  | $1.602 \times 10^{13}$        | $1.602 \times 10^{13}$     | $1.94 \times 10^{-5}$  | 16                  | 7                   | $1.957 \times 10^{-1}$       |
| 11  | $5.218 \times 10^{14}$        | $5.222 \times 10^{14}$     | $7.96 \times 10^{-4}$  | 16                  | 7                   | $2.042 \times 10^{-1}$       |
| 12  | $1.595 \times 10^{16}$        | $1.645 \times 10^{16}$     | $3.06 \times 10^{-2}$  | 17                  | 7                   | $2.118 \times 10^{-1}$       |

Table 8: Número de condição de  $H_n$  – método das potências vs.  $\text{cond}(\mathbf{A})$ .

$\text{cond}_2(H_n)$  cresce aproximadamente como  $e^{3.5n}$ , tornando  $H_n$  numericamente singular para  $n$  moderado. Para  $n = 12$  a comparação com  $\text{cond}(\mathbf{A})$  já não é fiável (erro relativo de 3%), reflexo da perda de precisão numérica na factorização LU. O método das potências inversas converge muito rapidamente (7–8 iterações) porque o rácio entre o segundo menor e o menor valor próprio é grande. O método das potências para o maior valor próprio converge em 13–17 iterações, com taxa teórica  $|\lambda_2/\lambda_1|$  a crescer de 0.133 para 0.212 à medida que  $n$  aumenta – consistente com o aumento gradual do número de iterações.

## 4.3 Alínea b-ii) – Matrizes de Lehmer $L_n$

| $n$ | cond <sub>2</sub> (potências) | cond <sub>2</sub> (MATLAB) | Erro rel.              | iter <sub>max</sub> | iter <sub>min</sub> | taxa $ \lambda_2/\lambda_1 $ |
|-----|-------------------------------|----------------------------|------------------------|---------------------|---------------------|------------------------------|
| 10  | $8.639 \times 10^1$           | $8.639 \times 10^1$        | $2.22 \times 10^{-10}$ | 19                  | 68                  | $3.085 \times 10^{-1}$       |
| 100 | $1.027 \times 10^4$           | $1.027 \times 10^4$        | $1.69 \times 10^{-9}$  | 19                  | 310                 | $2.984 \times 10^{-1}$       |
| 200 | $4.194 \times 10^4$           | $4.194 \times 10^4$        | $2.87 \times 10^{-9}$  | 19                  | 470                 | $2.983 \times 10^{-1}$       |
| 300 | $9.520 \times 10^4$           | (omitido)                  | (omitido)              | 19                  | 592                 | (omitido)                    |
| 400 | $1.701 \times 10^5$           | (omitido)                  | (omitido)              | 19                  | 691                 | (omitido)                    |
| 500 | $2.666 \times 10^5$           | (omitido)                  | (omitido)              | 19                  | 800                 | (omitido)                    |

Table 9: Número de condição de  $L_n$  – método das potências.

O número de condição de  $L_n$  cresce polinomialmente com  $n$  (aproximadamente  $O(n^2)$ ), muito mais lentamente do que  $H_n$ . O método das potências converge em apenas 19 iterações para todos os  $n$ , com taxa teórica  $|\lambda_2/\lambda_1| \approx 0.298$ – $0.309$ , estável com  $n$ . Em contraste, o método das potências inversas requer um número crescente de iterações (de 68 para 800), reflexo de que o rácio entre o segundo menor e o menor valor próprio de  $L_n$  se aproxima de 1 com  $n$ . Para  $n > 200$  omite-se a comparação com  $\text{cond}(\mathbf{A})$  por razões de eficiência.

## 4.4 Alínea c) – Gráfico de convergência para $H_8$

A Figura 4 mostra a convergência dos dois métodos das potências aplicados à matriz de Hilbert  $H_8$ , incluindo linhas de referência com as taxas de convergência teóricas  $|\lambda_2/\lambda_1|$  e  $|\lambda_{n-1}/\lambda_n|$  respectivamente. O método das potências (esquerda) converge linearmente

em 15 iterações, com taxa teórica  $|\lambda_2/\lambda_1| \approx 0.176$ , o que é consistente com o declive observado na escala logarítmica. O método das potências inversas (direita) converge em apenas 7 iterações, com declive muito mais acentuado, reflexo da grande separação entre os dois menores valores próprios de  $H_8$ .




Figure 4: Convergência dos métodos das potências para  $H_8$ . Esquerda: método das potências ( $|\lambda|_{\max}$ ) com referência teórica. Direita: método das potências inversas ( $|\lambda|_{\min}$ ) com referência teórica.